

Sprawozdanie z projektu R

Przedmiot: RPiS

Wydział Elektrotechniki, Automatyki, Informatyki i Inżynierii Biomedycznej
Kierunek: Automatyka i Robotyka

Emil Ścibich

Numer albumu: 43067

Grupa laboratoryjna: 9

1. Wykorzystane dane

W projekcie wykorzystano historyczny zbiór discoveries z pakietu R datasets. Zawiera on liczbę ważnych wynalazków i odkryć naukowych rejestrowanych rocznie w latach 1860–1959 (100 obserwacji). Dane pochodzą z publikacji D. R. McNeila, Interactive Data Analysis (Wiley, 1977) i są dostępne jako wbudowany szereg czasowy w R.

Dane zapisano do pliku CSV (do_projektu.csv, separator ;, format write.csv2), a następnie wczytano ponownie do analizy. Zmienna analizowana to roczna liczba odkryć (Liczba_Odkryc).

2. Postawione problemy badawcze

Problem 1 — zgodność z rozkładem Poissona

Czy roczna liczba odkryć można opisać rozkładem Poissona o nieznanym parametrze λ (model losowego występowania zdarzeń rzadkich)?

- H_0 : dane pochodzą z rozkładu Poissona(λ).
- H_1 : rozkład obserwacji nie jest zgodny z rozkładem Poissona.

Problem 2 — porównanie dwóch okresów

Czy średnia roczna liczba odkryć różni się między pierwszą a drugą połową analizowanego stulecia (lata 1860–1909 oraz 1910–1959)?

- H_0 : $\mu_1 = \mu_2$ (średnie w obu okresach są równe).
- H_1 : $\mu_1 \neq \mu_2$ (średnie w obu okresach są różne).

3. Zastosowane metody

Estymacja (problem 1): parametr λ oszacowano jako średnią arytmetyczną z 100 lat. Dla średniej z rozkładu Poissona zastosowano przybliżony 95% przedział ufności: $\hat{\lambda} \pm Z_{0,975} \cdot \sqrt{(\hat{\lambda}/n)}$.

Testowanie hipotez (problem 1): test chi-kwadrat zgodności z rozkładem Poissona. Obserwacje pogrupowano w 7 klas: 0, 1, 2, 3, 4, 5 oraz ≥ 6 odkryć rocznie. Prawdopodobieństwa teoretyczne wyznaczono z oszacowanego λ .

Estymacja (problem 2): obliczono średnie i odchylenia standardowe dla obu 50-letnich podzbiorów.

Testowanie hipotez (problem 2): dwustronny test t Welcha dla dwóch niezależnych prób (bez zakładania równości wariancji), poziom istotności $\alpha = 0,05$.

4. Wyniki analiz

4.1. Problem 1 — rozkład Poissona

Wielkość	Wartość
Liczba obserwacji n	100
Estymacja $\hat{\lambda}$	3,10
95% przedział ufności dla λ	[2,75; 3,45]
Statystyka χ^2	11,047
Stopnie swobody	6
p-value	0,0869

Ponieważ $p\text{-value} = 0,0869 > \alpha = 0,05$, nie ma podstaw do odrzucenia H_0 na zadanym poziomie istotności. Nie stwierdzono istotnej statystycznie niezgodności danych z modelem Poissona. Nie oznacza to jednak dowodu, że H_0 jest prawdziwa — przy większej mocy testu lub innym poziomie α wynik mógłby być inny.

4.2. Problem 2 — porównanie okresów

Okres	Lata	n	Średnia	Odchylenie std.
Pierwsza połowa	1860–1909	50	3,44	2,67
Druga połowa	1910–1959	50	2,76	1,89

Wielkość	Wartość
Statystyka t	1,518
Stopnie swobody (Welch)	92,73
p-value	0,1323
95% przedział ufności różnicy średnich	[−0,21; 1,57]

Ponieważ $p\text{-value} = 0,1323 > \alpha = 0,05$, nie ma podstaw do odrzucenia H_0 . Na podstawie tego testu nie wykazano istotnej różnicy między średnią liczbą odkryć w latach 1860–1909 i 1910–1959. Przedział ufności dla różnicy średnich obejmuje zero, co jest zgodne z tym wnioskiem.

5. Podsumowanie

Projekt spełnia wymagania zaliczenia na poziomie 5.0: wykorzystano dane historyczne, przeprowadzono estymację parametrów (λ , średnie, odchylenia standardowe, przedziały ufności) oraz testowanie hipotez (chi-kwadrat i t-test Welcha).

Roczna liczba odkryć nie odbiega istotnie od modelu Poissona ($p = 0,0869$), a średnie w dwóch analizowanych pięćdziesięcioleciach nie różnią się istotnie statystycznie ($p = 0,1323$). Ze względu na charakter szeregu czasowego wyniki należy interpretować ostrożnie — kolejne lata nie są w pełni niezależne, co jest uproszczeniem przy zastosowaniu klasycznego testu t.